

Informe Final: Gemelo Digital del Beamline

Proyecto Hackathon MIT-UNAL

Equipo Digital Twin

10 de julio de 2026

1. La cantidad modelada y justificación

Para la construcción de nuestro Gemelo Digital, decidimos **modelar la distribución espacial (perfil 2D) del haz de iones en el detector**, discretizada como un histograma aplanado de 400 dimensiones (20×20 bins, suavizado espacialmente mediante un filtro Gaussiano con $\sigma = 0,8$ para mitigar el ruido discreto). A partir de este perfil espacial, se deriva directamente la **transmisión** (suma total del histograma) y el **spread** o dispersión (desviación estándar espacial).

¿Por qué? Modelar únicamente un valor escalar como la transmisión genera un problema extremadamente difícil y propenso a quedarse en mínimos locales, ya que configuraciones muy diferentes de voltajes pueden producir la misma baja transmisión (un mapeo 'muchos a uno'). Al emular la distribución espacial completa, el modelo comprende la física de cómo el haz se deforma, se desplaza y se enfoca ante cambios en el campo eléctrico. Esto es vital para las tareas de control, ya que permite inferir la dirección del haz en la variedad y corregir distorsiones físicas.

2. Recolección de datos y cobertura espacial

El espacio de búsqueda de 8 dimensiones para los voltajes es enorme. Para asegurar una cobertura representativa, se utilizó una estrategia de **Latin Hypercube Sampling (LHS)** acotada a los rangos físicos permisibles (± 1000 V). Se recolectaron un total de **486 muestras** (combinación de LHS y pequeñas perturbaciones gaussianas con $\sigma = 20,0$ V sobre los 5 mejores puntos de alto rendimiento).

La elección de añadir perturbaciones en zonas prometedoras (densificación local de la variedad guiada por regiones de transmisión no nula) mitigó el problema de escasez de señal, garantizando que el modelo aprendiera la topología subyacente donde realmente llegan iones al detector, en lugar de predecir matrices nulas en regiones de colisión total. Esto enriqueció el dataset en el manifold útil, dotando al emulador de alta precisión local.

3. Arquitectura del Modelo e Hiperparámetros

Inspirados en la literatura reciente para control de aceleradores (Rautela et al., *CBOL-Tuner*), implementamos una arquitectura modular de Evolución Latente en 4D, dividida en componentes diferenciables:

1. **Compresión del Estado Físico (β -VAE):** Un Autoencoder Variacional que comprime el histograma del haz de 400 dimensiones a una variedad latente continua de 4 dimensiones ($z \in \mathbb{R}^4$).
 - *Encoder:* Capas densas [256, 128, 64] con ReLU y BatchNorm, proyectando a la media μ_z y log-varianza $\log \sigma_z^2$ en 4D.
 - *Decoder:* Capas densas [64, 128, 256, 400], con activación final **Softmax** multi-clase para modelar la forma probabilística pura.
 - *Pérdida:* Entropía Cruzada Multiclase (CE) + β Divergencia KL ($\beta = 0,005$). Se entrena únicamente en las muestras con impacto positivo ($T > 0$) para forzar al espacio latente a estructurar las geometrías de haz válidas.
2. **Emulador Forward Decoplado (DNN Regressor):** En lugar de emular el perfil directamente, estimamos las componentes del haz por separado:
 - *Forward Regressor (f_ψ):* MLP [64, 128, 64, 4] que predice la coordenada latente $\hat{z} \in \mathbb{R}^4$ a partir de los 8 voltajes y .
 - *Transmission Regressor (R_ω):* MLP [64, 128, 64, 1] con activación final Sigmoid que predice la transmisión escalar $T \in [0, 1]$.
 - *Emulador Compuesto:* $\hat{X} = R_\omega(y) \times \text{Decoder}(f_\psi(y))$. Es analíticamente diferenciable de extremo a extremo en PyTorch.

Para la validación, se empleó un esquema de separación de datos (split 80/20) manteniendo semillas pseudoaleatorias para garantizar reproducibilidad.

4. Resultados y validación (Predicción e Incertidumbre)

Durante el proceso de validación en la región informativa (donde existe transmisión de iones):

- La Fase 1 (VAE) logró una excelente convergencia con un error total ELBO en validación de **5.524675**.
- La Fase 2 (Forward Regressor) reportó un MSE de validación latente de **1.249795**. El regresor de transmisión paralela obtuvo un MSE escalar mínimo de **0.000213**.
- La Fase 3 (Inverse Estimator) para el mapeo inverso de voltajes logró un MSE de validación de ****0,034058****.

Comportamiento fuera de la región de entrenamiento e Incertidumbre: Para modelar y evitar la extrapolación no segura, entrenamos un **Kernel Density Estimator (KDE)** sobre el espacio latente del conjunto de entrenamiento. Establecimos un umbral en el percentil 5 de log-verosimilitud de $-3,9597$, escalando el ancho de banda a ****0,424**** para 4D. Cualquier predicción latente por debajo de este umbral se clasifica como 'extrapolación insegura/anomalía' y es rechazada por el optimizador, mitigando la incertidumbre epistémica (evitando alucinaciones del decodificador).

5. Control Inverso y Dirección (Optimización Latente)

Desarrollamos el algoritmo **C-BO (Classifier-Pruned Bayesian Optimization)** adaptando el KDE como podador de inviabilidad latente:

- **Dirección (Steering):** Se ejecutó Optuna (150 trials) sobre la variedad latente 4D acoplada al KDE. Se inyectaron los 5 mejores ensayos históricos como semillas. Posteriormente, los voltajes óptimos se refinaron mediante *retropropagación por gradiente (Adam)* a través del emulador Forward compuesto completo, aplicando regularización proximal L_2 ($\alpha = 2,0$).
- **Consigna Inversa:** Para replicar el Trial 104 objetivo (transmisión de 174 impactos), una red de estimación inversa proyectó las coordenadas latentes del objetivo:

$$z_{\text{target}} = [-0,1854, 0,4054, 0,8140, 1,2342]$$

a voltajes de partida, refinados por gradientes a través del emulador compuesto.

Resultados Físicos (SIMION): Al validar físicamente en SIMION:

- El punto óptimo de **Steering** logró un haz extraordinariamente colimado con una transmisión real del ****43,0 % (215/500 impactos)**** y spread de 2.960 (voltajes: $V_3 = -697,29$ V, $V_6 = -656,61$ V, $V_9 = -169,21$ V, $V_{10} = 280,02$ V, $V_{11} = 260,67$ V, $V_{12} = -333,86$ V, $V_{15} = 391,68$ V, $V_{18} = -671,93$ V).
- El control inverso de la **Consigna Inversa (Trial 104)** logró ****229/500 impactos reales (45,8 % de transmisión)**** con un spread de 2.774, superando la transmisión del haz original en 55 impactos (+31.6 % de eficiencia de corriente) con voltajes: $V_3 = -688,16$ V, $V_6 = -598,81$ V, $V_9 = -169,83$ V, $V_{10} = 210,28$ V, $V_{11} = 245,51$ V, $V_{12} = -337,16$ V, $V_{15} = 380,23$ V, $V_{18} = -647,76$ V.




Figura 1: Izquierda: Perfil predicho por el Forward Emulador en modo inferencia. Derecha: Perfil óptimo hallado tras la maximización Latente C-BO y refinamiento por retropropagación.




Figura 2: Resultados de Consigna Inversa. Izquierda: Perfil de haz objetivo. Derecha: Perfil reconstruido a partir de los voltajes inferidos por el Gemelo.

6. Metodología: Por qué este camino y no otro

Se optó deliberadamente por la Evolución Latente, la Separación de Componentes y el Desacoplamiento de la Transmisión en lugar de intentar predecir el impacto píxel a píxel directamente $\mathbb{R}^8 \rightarrow \mathbb{R}^{400}$. Mapear voltajes a un espacio de tan alta dimensión directamente es inestable frente a cambios caóticos (debido a la sensibilidad de las trayectorias de iones) y genera perfiles borrosos no físicos.

Por el contrario, el enfoque modular utilizado (1. Comprimir topología física $\mathbb{R}^{400} \rightarrow \mathbb{R}^4$, 2. Enlazar causas $y \rightarrow z$ y $y \rightarrow T$) obliga al modelo a generar únicamente distribuciones de haz válidas y bien definidas que el Autoencoder ha verificado físicamente, descartando el ruido estadístico no esencial. La adición del KDE en vez de utilizar redes adversarias para acotar los errores de extrapolación demostró ser una solución matemática económica y altamente efectiva.

7. Reflexión y Confiabilidad

¿Hasta dónde confiamos en el Gemelo?

Confiamos en el Gemelo Digital en el núcleo (*core*) de la variedad latente entrenada; para interpolaciones locales (donde existan impactos significativos), el modelo infiere trayectorias y voltajes óptimos en milisegundos sin requerir los prolongados 40 segundos de la simulación original de SIMION. El KDE acierta efectivamente al proteger al control inverso de explorar fuera de los regímenes físicos aprendidos.

¿Dónde no confiamos?

En escenarios de extremo esparcimiento (cero transmisión prolongada por barreras muy cerradas). El modelo agrupa todos los 'impactos perdidos' en un solo sumidero latente. Por tanto, para guiar ciegamente un haz desde un inicio en que todos los iones se pierden hasta enfocarlo, el gradiente proporcionado por el Gemelo se vuelve casi nulo. Para futuras mejoras, sería conveniente añadir información del punto donde se pierden los iones en el detector para generar un espacio de fase aún más continuo. En general, el sistema demostró un control superior respaldado por fundamentos teóricos del estado del arte.