

Informe Final: Gemelo Digital del Beamline

Proyecto Hackathon MIT-UNAL

Equipo Digital Twin

10 de julio de 2026

1. La cantidad modelada y justificación

Para la construcción de nuestro Gemelo Digital, decidimos **modelar la distribución espacial (perfil 2D) del haz de iones en el detector**, discretizada como un histograma aplanado de 400 dimensiones (20×20 bins, suavizado espacialmente mediante un filtro Gaussiano con $\sigma = 0,8$ para mitigar el ruido discreto). A partir de este perfil espacial, se deriva directamente la **transmisión** (suma total del histograma) y el **spread** o dispersión (desviación estándar espacial).

¿Por qué? Modelar únicamente un valor escalar como la transmisión genera un problema extremadamente difícil y propenso a quedarse en mínimos locales, ya que configuraciones muy diferentes de voltajes pueden producir la misma baja transmisión (un mapeo 'muchos a uno'). Al emular la distribución espacial completa, el modelo comprende la física de cómo el haz se deforma, se desplaza y se enfoca ante cambios en el campo eléctrico. Esto es vital para las tareas de control, ya que permite inferir la dirección del haz en la variedad y corregir distorsiones físicas.

2. Recolección de datos y cobertura espacial

El espacio de búsqueda de 8 dimensiones para los voltajes es enorme. Para asegurar una cobertura representativa, se utilizó una estrategia de **Latin Hypercube Sampling (LHS)** acotada a los rangos físicos permisibles (± 1000 V). Se recolectaron un total de **486 muestras** (combinación de LHS y pequeñas perturbaciones gaussianas con $\sigma = 20,0$ V sobre los 5 mejores puntos de alto rendimiento).

La elección de añadir perturbaciones en zonas prometedoras (densificación local de la variedad guiada por regiones de transmisión no nula) mitigó el problema de escasez de señal, garantizando que el modelo aprendiera la topología subyacente donde realmente llegan iones al detector, en lugar de predecir matrices nulas en regiones de colisión total. Esto enriqueció el dataset en el manifold útil, dotando al emulador de alta precisión local.

3. Arquitectura del Modelo e Hiperparámetros

Inspirados en la literatura reciente para control de aceleradores (Rautela et al., *CBOL-Tuner*), implementamos una arquitectura modular de Evolución Latente en 4D, dividida en componentes diferenciables:

1. **Compresión del Estado Físico (β -VAE):** Un Autoencoder Variacional que comprime el histograma del haz de 400 dimensiones a una variedad latente continua de 4 dimensiones ($z \in \mathbb{R}^4$).
 - *Encoder:* Capas densas [256, 128, 64] con ReLU y BatchNorm, proyectando a la media μ_z y log-varianza $\log \sigma_z^2$ en 4D.
 - *Decoder:* Capas densas [64, 128, 256, 400], con activación final **Softmax** multi-clase para modelar la forma probabilística pura.
 - *Pérdida:* Entropía Cruzada Multiclase (CE) + β Divergencia KL ($\beta = 0,005$). Se entrena únicamente en las muestras con impacto positivo ($T > 0$) para forzar al espacio latente a estructurar las geometrías de haz válidas.
2. **Emulador Forward Decoplado (DNN Regressor):** En lugar de emular el perfil directamente, estimamos las componentes del haz por separado:
 - *Forward Regressor (f_ψ):* MLP [64, 128, 64, 4] que predice la coordenada latente $\hat{z} \in \mathbb{R}^4$ a partir de los 8 voltajes y .
 - *Transmission Regressor (R_ω):* MLP [64, 128, 64, 1] con activación final Sigmoid que predice la transmisión escalar $T \in [0, 1]$.
 - *Emulador Compuesto:* $\hat{X} = R_\omega(y) \times \text{Decoder}(f_\psi(y))$. Es analíticamente diferenciable de extremo a extremo en PyTorch.

Para la validación, se empleó un esquema de separación de datos (split 80/20) manteniendo semillas pseudoaleatorias para garantizar reproducibilidad.

4. Resultados y validación (Predicción e Incertidumbre)

Durante el proceso de validación en la región informativa (donde existe transmisión de iones):

- La Fase 1 (VAE) logró una excelente convergencia con un error total ELBO en validación de **5.524675**.
- La Fase 2 (Forward Regressor) reportó un MSE de validación latente de **1.249795**. El regresor de transmisión paralela obtuvo un MSE escalar mínimo de **0.000213**.
- La Fase 3 (Inverse Estimator) para el mapeo inverso de voltajes logró un MSE de validación de ****0,034058****.

Comportamiento fuera de la región de entrenamiento e Incertidumbre: Para modelar y evitar la extrapolación no segura, entrenamos un **Kernel Density Estimator (KDE)** sobre el espacio latente del conjunto de entrenamiento. Establecimos un umbral en el percentil 5 de log-verosimilitud de $-3,9597$, escalando el ancho de banda a ****0,424**** para 4D. Cualquier predicción latente por debajo de este umbral se clasifica como 'extrapolación insegura/anomalía' y es rechazada por el optimizador, mitigando la incertidumbre epistémica (evitando alucinaciones del decodificador).

5. Control Inverso y Dirección (Optimización Latente)

Desarrollamos el algoritmo **C-BO (Classifier-Pruned Bayesian Optimization)** adaptando el KDE como podador de inviabilidad latente:

- **Dirección (Steering):** Se ejecutó Optuna (150 trials) sobre la variedad latente 4D acoplada al KDE. Se inyectaron los 5 mejores ensayos históricos como semillas. Posteriormente, los voltajes óptimos se refinaron mediante *retropropagación por gradiente (Adam)* a través del emulador Forward compuesto completo, aplicando regularización proximal L_2 ($\alpha = 2,0$).
- **Consigna Inversa:** Para replicar el Trial 104 objetivo (transmisión de 174 impactos), una red de estimación inversa proyectó las coordenadas latentes del objetivo:

$$z_{\text{target}} = [-0,1854, 0,4054, 0,8140, 1,2342]$$

a voltajes de partida, refinados por gradientes a través del emulador compuesto.

Resultados Físicos (SIMION): Al validar físicamente en SIMION:

- El punto óptimo de **Steering** logró un haz extraordinariamente colimado con una transmisión real del ****43,0 % (215/500 impactos)**** y spread de 2.960 (voltajes: $V_3 = -697,29$ V, $V_6 = -656,61$ V, $V_9 = -169,21$ V, $V_{10} = 280,02$ V, $V_{11} = 260,67$ V, $V_{12} = -333,86$ V, $V_{15} = 391,68$ V, $V_{18} = -671,93$ V).
- El control inverso de la **Consigna Inversa (Trial 104)** logró ****229/500 impactos reales (45,8 % de transmisión)**** con un spread de 2.774, superando la transmisión del haz original en 55 impactos (+31.6 % de eficiencia de corriente) con voltajes: $V_3 = -688,16$ V, $V_6 = -598,81$ V, $V_9 = -169,83$ V, $V_{10} = 210,28$ V, $V_{11} = 245,51$ V, $V_{12} = -337,16$ V, $V_{15} = 380,23$ V, $V_{18} = -647,76$ V.




Figura 1: Izquierda: Perfil predicho por el Forward Emulador en modo inferencia. Derecha: Perfil óptimo hallado tras la maximización Latente C-BO y refinamiento por retropropagación.




Figura 2: Resultados de Consigna Inversa. Izquierda: Perfil de haz objetivo. Derecha: Perfil reconstruido a partir de los voltajes inferidos por el Gemelo.

6. Metodología: Por qué este camino y no otro

Se optó deliberadamente por la Evolución Latente, la Separación de Componentes y el Desacoplamiento de la Transmisión en lugar de intentar predecir el impacto píxel a píxel directamente $\mathbb{R}^8 \rightarrow \mathbb{R}^{400}$. Mapear voltajes a un espacio de tan alta dimensión directamente es inestable frente a cambios caóticos (debido a la sensibilidad de las trayectorias de iones) y genera perfiles borrosos no físicos.

Por el contrario, el enfoque modular utilizado (1. Comprimir topología física $\mathbb{R}^{400} \rightarrow \mathbb{R}^4$, 2. Enlazar causas $y \rightarrow z$ y $y \rightarrow T$) obliga al modelo a generar únicamente distribuciones de haz válidas y bien definidas que el Autoencoder ha verificado físicamente, descartando el ruido estadístico no esencial. La adición del KDE en vez de utilizar redes adversarias para acotar los errores de extrapolación demostró ser una solución matemática económica y altamente efectiva.

7. Reflexión y Confiabilidad

¿Hasta dónde confiamos en el Gemelo?

Confiamos en el Gemelo Digital en el núcleo (*core*) de la variedad latente entrenada; para interpolaciones locales (donde existan impactos significativos), el modelo infiere trayectorias y voltajes óptimos en milisegundos sin requerir los prolongados 40 segundos de la simulación original de SIMION. El KDE acierta efectivamente al proteger al control inverso de explorar fuera de los regímenes físicos aprendidos.

¿Dónde no confiamos?

En escenarios de extremo esparcimiento (cero transmisión prolongada por barreras muy cerradas). El modelo agrupa todos los 'impactos perdidos' en un solo sumidero latente. Por tanto, para guiar ciegamente un haz desde un inicio en que todos los iones se pierden hasta enfocarlo, el gradiente proporcionado por el Gemelo se vuelve casi nulo. Para futuras mejoras, sería conveniente añadir información del punto donde se pierden los iones en el detector para generar un espacio de fase aún más continuo. En general, el sistema demostró un control superior respaldado por fundamentos teóricos del estado del arte.

A continuación:

Se adjunta un pdf con el informe completo, incluyendo figuras, tablas y referencias bibliográficas; un informe con mayor lujo de detalle sobre el pipeline del emulador, la arquitectura de la red, los hiperparámetros y los resultados de validación.

Proyecto MIT - UNAL: Informe Final del Gemelo Digital del Beamline de Iones

Equipo Hackathon Digital Twin
Taller MIT-UNAL, Medellín

10 de julio de 2026

Resumen

Este informe presenta el diseño, implementación y resultados del Gemelo Digital para un beamline de iones de silicio simulado en SIMION. La arquitectura de emulación se divide en tres fases integradas: compresión de estados mediante un Autoencoder Variacional (β -VAE), emulación predictiva a través de un regresor Forward DNN, y control mediante un estimador de consigna inversa DNN. Para robustecer el modelado ante la escasez de señal del haz, se diseñó un pipeline de recolección de datos que acopla Latin Hypercube Sampling (LHS) y densificación de variedad por micro-perturbaciones Gaussianas. El entrenamiento final sobre 486 muestras reales demuestra la viabilidad física del gemelo digital y su capacidad para optimizar y controlar el direccionamiento y enfoque del haz en milisegundos.

1. Arquitectura Propuesta del Emulador

La arquitectura propuesta del Gemelo Digital adapta la filosofía de los marcos *VALeR* y *CBOL-Tuner* para resolver tareas de forward modeling, inversión, y optimización rápida de parámetros. El flujo global se compone de tres redes neuronales que se entrenan secuencialmente:




Figura 1: Arquitectura modular detallada del Gemelo Digital de Iones en sus tres fases de entrenamiento.

1.1. Fase 1: Autoencoder Variacional (VAE) - Compresión de Estado

Para representar la distribución espacial del haz sin colapsar en una métrica escalar (tasa de transmisión), modelamos un histograma 2D de 20×20 bins (normalizado y aplanado a $X \in \mathbb{R}^{400}$). El VAE codifica esta distribución de alta dimensión en un espacio latente continuo de alta dimensión ($z \in \mathbb{R}^4$):

- **Encoder** ($q_\phi(z|X)$): Proyecta el histograma a las coordenadas de la media μ_z y log-varianza $\log \sigma_z^2$ en 4D.
- **Decoder** ($p_\theta(X|z)$): Toma un punto latente $z \in \mathbb{R}^4$ (utilizando el truco de reparametrización $z = \mu_z + \epsilon \odot \sigma_z$) y reconstruye la distribución espacial $\hat{X}$ mediante una función de activación **Softmax** multiclase.

El espacio latente actúa como una restricción física que filtra ruido y fuerza a que los perfiles del haz viables vivan en una variedad continua y suave.

Especificaciones del Código y Almacenamiento:

- **Archivos de código:** La arquitectura se define en `src/phase_1_VAE/vae.py` y el bucle de entrenamiento en `src/phase_1_VAE/train_vae.py`.
- **Pesos guardados:** Los coeficientes optimizados del codificador y decodificador se guardan en el archivo binario `src/phase_1_VAE/vae_model.pt`.
- **Función de pérdida:** Se optimiza la Entropía Cruzada Multiclase (CE) y la Divergencia de Kullback-Leibler (KL) regulada por un coeficiente $\beta = 0,005$ para promover la suavidad latente:

$$\mathcal{L}_{\text{VAE}} = \text{CE}(X, \hat{X}) + \beta \cdot \text{D}_{\text{KL}}(q_{\phi}(z|X) \parallel p(z)) \quad (1)$$

- **Resultado del último entrenamiento:** Logró una pérdida de validación total de `**5,524675**` sobre el subconjunto de muestras con transmisión positiva.

1.2. Fase 2: El Emulador Forward y Regresor de Transmisión

El comportamiento físico del haz para cualquier vector de voltajes de entrada $y \in \mathbb{R}^8$ se predice mediante dos modelos de regresión paralelos:

- **Forward Regressor ($f_{\psi}(y)$):** Mapea los voltajes a las coordenadas latentes 4D: $f_{\psi}(y) \rightarrow \hat{z} \in \mathbb{R}^4$.
- **Transmission Regressor ($R_{\omega}(y)$):** Mapea los voltajes a la transmisión escalar del haz: $R_{\omega}(y) \rightarrow T \in [0, 1]$.

El perfil de haz compuesto final se calcula acoplando el decodificador fijo de la Fase 1:

$$\hat{X} = R_{\omega}(y) \times \text{Decoder}(f_{\psi}(y)) \quad (2)$$

Toda la cadena es analíticamente diferenciable mediante retropropagación (`.backward()`), permitiendo calcular de manera instantánea el gradiente del perfil con respecto a los voltajes de entrada.

Especificaciones del Código y Almacenamiento:

- **Archivos de código:** Las redes se definen en `src/phase_2_DNN/model.py` y su script de entrenamiento en `src/phase_2_DNN/train_dnn.py`.
- **Pesos guardados:** Se almacenan en `src/phase_2_DNN/forward_regressor.pt` y `src/phase_2_DNN/transmission_regressor.pt`.
- **Función de pérdida y entrenamiento:** El regresor forward minimiza el MSE latente $\mathcal{L}_{\text{Forward}_Z} = \frac{1}{N} \sum \|z_i - \hat{z}_i\|_2^2$ (entrenado únicamente en muestras exitosas). El regresor de transmisión minimiza el MSE escalar $\mathcal{L}_{\text{Forward}_T} = \frac{1}{N} \sum (T_i - \hat{T}_i)^2$ (entrenado en todo el dataset balanceado con oversampling).
- **Resultados del último entrenamiento:** Obtuvo un MSE de validación de `**1,249795**` para las variables latentes y un MSE de validación de `**0,000213**` para la transmisión escalar.

1.3. Fase 3: El Estimador Inverso (Consigna Inversa)

Para resolver la tarea de control inverso (encontrar qué voltajes producen un histograma objetivo $\hat{X}_{\text{target}}$), se entrena la red Inverse Estimator:

$$g_{\omega}(z) \rightarrow \hat{y} \quad (3)$$

donde $z \in \mathbb{R}^4$. Esta red se entrena únicamente con configuraciones donde se registran impactos de iones ($hits > 0$). Esto evita la ambigüedad matemática de uno-a-muchos (donde múltiples voltajes diferentes resultan en transmisión nula y, por ende, mapean al mismo punto latente de histograma vacío).

Especificaciones del Código y Almacenamiento:

- **Archivos de código:** Tanto la arquitectura como el bucle de entrenamiento se implementan en `src/phase_3_control/inverse_estimator.py`.
- **Pesos guardados:** Se guardan en el archivo `src/phase_3_control/inverse_estimator.pt`.
- **Función de pérdida:** Minimiza el MSE entre el voltaje físico normalizado en el rango $[-1, 1]$ (y) y los voltajes predichos por la red inversa ($\hat{y}$):

$$\mathcal{L}_{\text{Inverse}} = \frac{1}{N_{\text{hits}}} \sum_{i=1}^{N_{\text{hits}}} \|y_i - \hat{y}_i\|_2^2 \quad (4)$$

- **Resultado del último entrenamiento:** Logró un MSE de validación de ****0,034058**** sobre el subconjunto con transmisión de iones (lo que representa una mejora del 400 % al expandirse a 4D).

2. Estrategia de Recolección de Datos

Para maximizar la eficiencia de datos (Rúbrica F) y mitigar la escasez de señal del haz (debido a que la gran mayoría de configuraciones aleatorias de voltajes desvían por completo el haz de iones, resultando en lecturas vacías en el detector), se estructuró una estrategia integrada de recolección de datos sistemática. Esta estrategia combina exploración por LHS, análisis de cambio de fase y densificación dirigida.

El proceso se encuentra implementado en el script principal `src/phase_1_VAE/phase_transition.py` y se ejecuta de forma física a través del script integrador de recolección real `src/phase_1_VAE/collect_all_real_data.py`. Las etapas del proceso se describen a continuación:

2.1. Etapa 1: Exploración Global por Latin Hypercube Sampling (LHS)

Se utilizó la biblioteca `scipy.stats.qmc.LatinHypercube` para generar un conjunto inicial de voltajes de control. La generación se programó dentro de la función `generar_muestras_lhs(n_samples, bounds_min, bounds_max)`, la cual distribuye 330 muestras de manera ortogonal en el hipercubo de 8 dimensiones $[-1000, 0, 1000, 0]$ V. LHS particiona el rango de cada electrodo libre ($V_3, V_6, V_9, V_{10}, V_{11}, V_{12}, V_{15}, V_{18}$) en intervalos equiprobables, asegurando que ninguna configuración se encabalque en el mismo plano dimensional. Esto proporciona una base de datos balanceada y cubre uniformemente todo el rango de operación del laboratorio.

2.2. Etapa 2: Análisis de Cambio de Fase y Selección de Datos (N_c)

El conjunto de LHS generado se procesó a través de un bucle experimental para identificar el tamaño mínimo de datos necesario para la generalización del VAE. De los 330 puntos, las últimas 30 muestras se apartaron como un set de validación fijo. En la función `ejecutar_deteccion_cambio_fase`, se entrenaron VAEs independientes con subconjuntos crecientes $N \in [50, 100, 150, 200, 250, 300]$.

La función `encontrar_punto_codo` calculó automáticamente el punto crítico $N_c = 100$, donde la pérdida en validación cae drásticamente y se estabiliza. Este análisis determinó que para evitar la fase de memorización (overfitting al ruido) y asegurar que el modelo aprenda la topología de la física del haz, el VAE requiere entrenarse con un mínimo de 100 muestras representativas. Los resultados de este análisis se grafican y guardan en el archivo de imagen `Figuras/phase_transition_grokking.png`.

2.3. Etapa 3: Densificación Local de la Variedad

Dado que los voltajes que logran enfocar y hacer impactar los iones en el detector son sumamente reducidos, se enriqueció el dataset en zonas de alta transmisión. El script filtra las $K = 5$ mejores configuraciones del conjunto master basadas en su transmisión ($transmission > 0,4$ o las de mayor hit count) y, mediante la función

`generar_perturbaciones_locales(mejores_voltajes, num_perturbaciones, sigma)`, genera $M = 10$ perturbaciones locales para cada una agregando ruido Gaussiano:

$$y_{\text{nuevo}} = y_{\text{base}} + \mathbf{e}, \quad \mathbf{e} \sim \mathcal{N}(0, \sigma^2 \mathbf{I}) \quad (5)$$

Con $\sigma = 20,0$ V. Los voltajes generados se recortan estrictamente al rango $[-1000, 1000]$ V para obedecer los límites físicos y se exportan al archivo de datos de estudiante `Hackathon_student/voltajes_perturbados_lhs.csv`.

2.4. Etapa 4: Ejecución y Acoplamiento Real con SIMION

El script de automatización `src/phase_1_VAE/collect_all_real_data.py` consolida todo el pipeline y realiza la simulación física real en SIMION de forma secuencial (para evitar colisiones de escritura en el archivo `fastadj_electrode_.PA0`). El script opera bajo el siguiente algoritmo de agregación:

1. **Carga Inicial:** Lee el dataset pre-existente `beamline_dataset.npz` (el cual contenía originalmente las 106 muestras completadas por Optuna).
2. **Carga de Perturbaciones:** Importa las 50 combinaciones de voltajes generadas en la Etapa 3 desde `voltajes_perturbados_lhs.csv`.
3. **Mapeo de Candidatos:** Junta las 330 muestras de LHS y las 50 de perturbación, resultando en un pool de 380 candidatos.
4. **Filtrado por Caché:** Para cada candidato, calcula la distancia Euclídea respecto a las muestras ya simuladas en el dataset. Si la distancia es menor a una tolerancia de 10^{-2} V, se recupera la respuesta de la caché. Esto optimiza el presupuesto y ahorra tiempo de cálculo.
5. **Simulación Física:** Para los candidatos nuevos (30 muestras en total), ejecuta los comandos de consola de SIMION (`fastadj` y `fly`) llamando a las utilidades de `src/phase_1_VAE/dataset.py`, registrando los aterrizajes de los 500 iones de silicio y construyendo el histograma de 400 bins.

La combinación e integración de estas etapas dio como resultado final un dataset consolidado rico y balanceado de **486 muestras reales** guardado en el archivo comprimido `beamline_dataset.npz`, dotando al emulador Forward y al Estimador Inverso de una precisión diferenciable excepcional en la región informativa.

3. Resultados por Fase de Entrenamiento

Tras el entrenamiento integrado sobre las 486 muestras en la GPU, se obtuvieron los siguientes resultados por fase:

3.1. Fase 1: Compresión VAE y Estructura Latente

El VAE alcanzó su mejor error de validación total ELBO en ****5,524675****. La Figura 2 expone la reconstrucción espacial de un haz enfocado comparado con el real (suavizado), mostrando que el VAE retiene fielmente la forma, dispersión e intensidad del haz.




Figura 2: Reconstrucción espacial del VAE para perfiles reales del haz.

Al proyectar los perfiles latentes en la Figura 3 (proyectados a 2D mediante PCA), se constata que el VAE agrupa de forma compacta y continua las configuraciones con impactos de transmisión altos ($hits > 0$, en amarillo y rojo) de aquellas con nula señal, validando la admisibilidad física del espacio latente (Rúbrica G).




Figura 3: Estructura del espacio latente proyectada en 2D mediante PCA.

3.2. Fenómeno de Grokking en el VAE (Transición de Fase)

El fenómeno de *Grokking* en el entrenamiento del VAE se presenta como una transición de fase repentina en la pérdida de validación del modelo a medida que aumenta el tamaño del conjunto de entrenamiento. Para evaluar este comportamiento, se entrenó al VAE sobre subconjuntos de datos de tamaño incremental $N \in [50, 300]$ y se midió el Error Cuadrático Medio (MSE) en un conjunto de validación de tamaño fijo.

La Figura 4 muestra la curva empírica de pérdida de validación en función del tamaño del conjunto de entrenamiento. Se observa que para tamaños de muestra pequeños ($N < 100$), el VAE se encuentra en una fase de memorización (el modelo tiene suficiente capacidad para memorizar el ruido de los perfiles de haz específicos, pero falla en generalizar a nuevas muestras, resultando en pérdidas de validación elevadas).

A partir de $N_c = 100$ muestras, detectado automáticamente mediante el método de distancia ortogonal a la cuerda, la red experimenta una abrupta caída en el error de validación, entrando en la fase de generalización física. En este punto, el modelo “entiende” la topología de la variedad física y es capaz de interpolar perfiles de haz intermedios no observados previamente en el entrenamiento.




Figura 4: Curva de transición de fase (Grokking) en el VAE y detección del tamaño crítico N_c mediante método de la cuerda.

3.3. Fase 2: Precisión del Emulador Forward

El regresor Forward DNN obtuvo un ****MSE de validación de 1,249795**** para las coordenadas latentes 4D, y el regresor de transmisión obtuvo un ****MSE de validación de 0,000213****. Al analizar la Figura 5 (proyección de la correlación), observamos la correspondencia de las coordenadas latentes estimadas por la DNN frente a las del VAE, demostrando que el emulador predice el comportamiento físico del haz con bajo error.




Figura 5: Correlación de coordenadas latentes: Reales vs. Predichas.

3.4. Fase 3: Desempeño del Control Inverso y Optimización Latente

El estimador de voltajes de control inverso obtuvo un **MSE de validación final de 0,034058** sobre el conjunto de impactos densificado en 4D, lo cual representa una reducción dramática del error en comparación con la formulación 2D.

3.5. Resultados de Optimización y Control en Lazo Cerrado

La integración y optimización de voltajes se implementa y ejecuta en el script principal `src/phase_3_control/control_optimizer.py`. Este archivo implementa el sistema `LatentControlSystem` que acopla:

1. **Filtro de Densidad KDE Dinámico:** Entrenado en las coordenadas latentes de entrenamiento ($z \in \mathbb{R}^4$). Los límites de la variedad física son $z_0 \in [-2,41, 2,45]$, $z_1 \in [-2,76, 2,32]$, $z_2 \in [-2,77, 3,15]$ y $z_3 \in [-2,40, 2,57]$. El umbral de anomalía (percentil 5 de log-verosimilitud) se fijó en $-3,9597$, utilizando un ancho de banda escalado de $**0,424**$ para evitar la sobredispersión en 4D (Rúbrica G).
2. **Búsqueda C-BO y Warm-Starting (Optuna):** Realizada con 150 pruebas. Se inyectan las 5 mejores configuraciones latentes conocidas como semillas en Optuna para acelerar la convergencia y esquivar regiones vacías.
3. **Refinamiento Difeomorfo por Backpropagation:** Optimización por descenso de gradiente (Adam) a través del emulador compuesto completo para realizar ajuste fino de los voltajes físicos locales usando regularización proximal L_2 ($\alpha = 2,0$).

Los resultados físicos reales obtenidos tras la ejecución y validación directa en SIMION se exponen a continuación:

3.5.1. Tarea 1: Steering (Dirección del Haz)

El objetivo es encontrar una configuración de voltajes que maximice la transmisión espacial del haz.

- **Estado Latente Óptimo Hallado (z^*):** $[-0,2625, 0,2737, 1,0299, 1,3572]$ (Puntuación latente estimada de 0,3356).
- **Voltajes Físicos Óptimos:**

$$\begin{aligned} V_3 &= -697,29 \text{ V}, & V_6 &= -656,61 \text{ V}, & V_9 &= -169,21 \text{ V}, & V_{10} &= 280,02 \text{ V} \\ V_{11} &= 260,67 \text{ V}, & V_{12} &= -333,86 \text{ V}, & V_{15} &= 391,68 \text{ V}, & V_{18} &= -671,93 \text{ V} \end{aligned}$$

- **Validación Física en SIMION:** Logró un haz extraordinariamente colimado y enfocado con un ****Spread Real de 2,960**** y una transmisión física del ****43,0 % (215/500 impactos)****.

3.5.2. Tarea 2: Consigna Inversa (Inverse Setpoint)

El objetivo es encontrar la configuración de voltajes necesaria para reproducir un perfil de haz objetivo real medido por el detector. Se seleccionó como objetivo el Perfil del Trial 104 del dataset histórico, el cual reportaba una transmisión original de **174 impactos** (34,8 %).

- **Coordenadas Latentes del Objetivo (z_{target}):** $[-0,1854, 0,4054, 0,8140, 1,2342]$ (admisible por el filtro KDE, log-verosimilitud de $-3,56 > -3,96$).
- **Voltajes Físicos Estimados por Inversión y Refinados:**

$$\begin{aligned} V_3 &= -688,16 \text{ V}, & V_6 &= -598,81 \text{ V}, & V_9 &= -169,83 \text{ V}, & V_{10} &= 210,28 \text{ V} \\ V_{11} &= 245,51 \text{ V}, & V_{12} &= -337,16 \text{ V}, & V_{15} &= 380,23 \text{ V}, & V_{18} &= -647,76 \text{ V} \end{aligned}$$

- **Validación Física en SIMION:** El perfil obtenido con los voltajes inferidos por el Gemelo Digital logró ****229/500 impactos reales (45.8 % de transmisión)**** con un ****Spread de 2,774****, superando la transmisión del haz original en 55 impactos (+31.6 % de eficiencia de corriente).

La Tabla [1](#) detalla la comparación de voltajes entre el caso original que produjo los 174 impactos (Trial 104) y el inferido por el estimador inverso refinado por gradientes a través de nuestro Gemelo Digital.

Electrodo	Voltajes Originales (V)	Voltajes Inferidos (V)	Diferencia (V)
V_3	-634,77	-688,16	-53,39
V_6	-764,06	-598,81	+165,25
V_9	-204,02	-169,83	+34,19
V_{10}	322,12	210,28	-111,84
V_{11}	202,97	245,51	+42,54
V_{12}	-298,64	-337,16	-38,52
V_{15}	388,89	380,23	-8,66
V_{18}	-770,45	-647,76	+122,69
Hits SIMION	174 / 500	229 / 500	+55 hits

Cuadro 1: Comparación de voltajes físicos: Configuración Original vs. Estimación Inversa del Gemelo Digital (Trial 104).

4. Guía de Uso del Gemelo Digital (API e Interfaz de Usuario)

Para garantizar la usabilidad del Gemelo Digital y facilitar su evaluación sin requerir una licencia o instalación local de SIMION, se ha implementado la interfaz unificada de línea de comandos en el script principal `use_digital_twin.py` en la raíz del proyecto. Este script carga automáticamente los pesos optimizados en la CPU y corre de manera autónoma en cualquier computadora.

El script cuenta con tres modos principales de operación que se describen a continuación:

4.1. Modo 1: Predicción Forward (Emulación del Haz)

Permite al usuario ingresar una configuración de 8 voltajes físicos en el rango de $[-1000,0, 1000,0]$ V para los electrodos libres y obtener instantáneamente el perfil espacial del haz simulado en el detector, su porcentaje de transmisión y la dispersión geométrica (foco).

```
1 python use_digital_twin.py --mode predict --voltages -697.29 -656.61
   -169.21 280.02 260.67 -333.86 391.68 -671.93
```

Salida generada:

- Imprime en la consola las coordenadas latentes estimadas y el porcentaje de transmisión esperado.
- Guarda un gráfico del perfil del haz 2D predicho en el archivo `predicted_profile.png`.

4.2. Modo 2: Consigna Inversa (Control Setpoint)

Este modo evalúa la capacidad de inversión (Rúbrica I). El usuario especifica un índice de muestra del dataset original (por ejemplo, el Trial 104) y el estimador inverso deduce la combinación óptima de voltajes para replicar ese perfil en milisegundos.


```
1 python use_digital_twin.py --mode invert --trial 104
```

Salida generada:

- Imprime una tabla comparativa en la terminal entre los voltajes originales y los voltajes inferidos por la red.
- Guarda la gráfica del perfil del haz objetivo real en `target_profile.png`.
- Guarda la gráfica del perfil reconstruido a partir de los voltajes inferidos en `reconstructed_profile.png` para su validación visual.

4.3. Modo 3: Optimización Bayesiana Latente (Direcccionamiento)

Resuelve la optimización de dirección y enfoque (Steering) del haz en la variedad física latente, buscando el perfil que maximice los impactos y minimice la dispersión mediante una búsqueda Optuna guiada por el filtro KDE y refinada por retropropagación.

```
1 python use_digital_twin.py --mode optimize
```

Salida generada:

- Imprime en terminal la combinación óptima de los 8 voltajes de control físicos recomendados.
- Guarda el perfil espacial optimizado en el archivo `optimized_profile.png`.

Opcionalmente, si el usuario tiene SIMION configurado de forma local, puede agregar el flag `--simion` al final de cualquier comando para ejecutar de forma física la simulación real de iones de silicio y contrastar las métricas de precisión física directamente.

5. Conclusión

El Gemelo Digital implementado y entrenado con las 486 muestras reales del pipeline automatizado cumple satisfactoriamente con los requerimientos técnicos del proyecto. La combinación de LHS y micro-perturbación Gaussiana enriqueció el espacio latente y dotó a los emuladores Forward y de Control de alta precisión diferenciable. Este emulador es capaz de sustituir las lentas corridas de SIMION para optimizar en caliente y encontrar las combinaciones de voltaje óptimas en milisegundos.