

Informe Final: Gemelo Digital del Beamline

Proyecto Hackathon MIT-UNAL

Equipo Digital Twin

9 de julio de 2026

1. La cantidad modelada y justificación

Para la construcción de nuestro Gemelo Digital, decidimos **modelar la distribución espacial (perfil 2D) del haz de iones en el detector**, discretizada como un histograma aplanado de 400 dimensiones (20×20). A partir de este perfil espacial, se deriva directamente la **transmisión** (suma total del histograma) y el **spread** o dispersión (desviación estándar espacial).

¿Por qué? Modelar únicamente un valor escalar como la transmisión genera un problema extremadamente difícil y propenso a quedarse en mínimos locales, ya que configuraciones muy diferentes de voltajes pueden producir la misma baja transmisión (un mapeo 'muchos a uno'). Al emular la distribución espacial completa, el modelo comprende la física de cómo el haz se deforma, se desplaza y se enfoca ante cambios en el campo eléctrico. Esto es vital para las tareas de control, ya que permite inferir si el haz chocó contra la pared superior o inferior antes de llegar al detector.

2. Recolección de datos y cobertura espacial

El espacio de búsqueda de 8 dimensiones para los voltajes es enorme. Para asegurar una cobertura representativa, se utilizó una estrategia de **Latin Hypercube Sampling (LHS)** acotada a los rangos físicos permisibles (típicamente ± 1000 V). Se recolectaron un total de **486 muestras** (combinación de LHS y pequeñas perturbaciones gaussianas sobre puntos de alto rendimiento).

La elección de añadir perturbaciones en zonas prometedoras (aprendizaje activo guiado por regiones de transmisión no nula) mitigó el problema de escasez de señal, garantizando que el modelo aprendiera la topología subyacente donde realmente llegan iones al detector, en lugar de predecir matrices nulas en regiones de colisión total. La cobertura del espacio de las muestras útiles fue agrupada de manera natural en un sub-espacio continuo y estructurado gracias a la reducción de dimensionalidad empleada.

3. Arquitectura del Modelo e Hiperparámetros

Inspirados en la literatura reciente para control de aceleradores (Rautela et al., *CBOL-Tuner*), implementamos una arquitectura modular de Evolución Latente dividida en dos componentes diferenciables, que entrenamos de manera aislada:

1. **Compresión del Estado Físico (β -VAE):** Un Autoencoder Variacional que comprime el histograma del haz de 400 dimensiones a una variedad latente de tan solo 2 dimensiones ($z \in \mathbb{R}^2$).
 - *Encoder:* Capas densas [256, 128, 64] con ReLU y BatchNorm.
 - *Decoder:* Capas densas [64, 128, 256, 400], con activación Sigmoid en la salida.
 - *Pérdida:* Reconstrucción (MSE) + β KL Divergence.
2. **Emulador Forward (DNN Regressor):** Una red neuronal densa que proyecta los 8 voltajes y (entradas del sistema) a las coordenadas del espacio latente z .
 - *Arquitectura:* Capas densas [64, 128, 64, 2].

Para la validación de ambos sistemas, se empleó un esquema de separación de datos (split 80/20) guardando semillas pseudoaleatorias para mantener determinismo. El ensemble total toma los 8 voltajes, los predice en el latente (DNN) y los decodifica (VAE).

4. Resultados y validación (Predicción e Incertidumbre)

Durante el proceso de validación en la región informativa (donde existe transmisión de iones):

- La Fase 1 (VAE) logró una convergencia excelente con un MSE de reconstrucción final de **0.057**. El espacio latente demostró una alta capacidad para separar cúmulos de impactos altos de los nulos.
- La Fase 2 (Forward Regressor) reportó un MSE de validación en las coordenadas latentes de **0.256**.

Comportamiento fuera de la región de entrenamiento e Incertidumbre: Para modelar y evitar la extrapolación no segura, ajustamos un **Kernel Density Estimator (KDE)** sobre el espacio latente del conjunto de entrenamiento. Establecimos un umbral en el percentil 5 de log-verosimilitud (log-likelihood). Cualquier predicción de estados latentes por debajo de esta densidad se cataloga como 'extrapolación insegura / alucinación'. Esta compuerta de admisibilidad nos permitió acotar la incertidumbre epistémica del modelo: si el estimador visita regiones no físicas, el KDE rechaza la predicción.

5. Control Inverso y Dirección (Optimización Latente)

Desarrollamos el algoritmo **C-BO (Classifier-Pruned Bayesian Optimization)** adaptando el KDE como 'clasificador de viabilidad':

- **Dirección (Steering):** Se ejecutó Optuna en el espacio latente 2D para maximizar los impactos. En cada intento, el KDE podó las proposiciones inviables. Finalmente, los voltajes inferidos se refinaron mediante *retropropagación a través del emulador Forward* (como si fuera *Deep Dream*).

- **Consigna Inversa:** Para replicar el Trial 104 objetivo, una red de estimación inversa proyectó el z deseado a voltajes y_{init} , y retropropagamos los gradientes para asegurar consistencia.

Resultados Físicos (SIMION): Al validar el control inverso de nuestro modelo, SIMION arrojó **130 de 500 impactos (26.0% de transmisión)** con un Spread muy estrecho de 2.749, lo que verifica que las estrategias del gemelo retienen coherencia con la física genuina del entorno, y son efectivas para un escenario de consigna real.




Figura 1: Izquierda: Perfil predicho por el Forward Emulator en modo inferencia. Derecha: Perfil óptimo hallado tras la maximización Latente C-BO y refinamiento por retropropagación.




Figura 2: Resultados de Consigna Inversa. Izquierda: Perfil de haz objetivo. Derecha: Perfil reconstruido a partir de los voltajes inferidos por el Gemelo.

6. Metodología: Por qué este camino y no otro

Se optó deliberadamente por la Evolución Latente y la Separación de Componentes en lugar de intentar predecir el impacto píxel a píxel a partir de un enorme Vector Densa. Intentar mapear las entradas físicas $\mathbb{R}^8 \rightarrow \mathbb{R}^{400}$ directamente es inestable frente a cambios caóticos (muy comunes en distribuciones de iones paraxiales) e introduce ruido.

Por el contrario, el enfoque modular utilizado (1. Comprimir topología física $\mathbb{R}^{400} \rightarrow \mathbb{R}^2$, 2. Enlazar causas $y \rightarrow z$) obliga al modelo a generar únicamente distribuciones de haz válidas que el Autoencoder ha verificado físicamente, descartando el ruido estadístico no esencial. La adición del KDE en vez de utilizar redes adversarias para acotar los errores de extrapolación demostró ser una solución económica a la par de efectiva.

7. Reflexión y Confiabilidad

¿Hasta dónde confiamos en el Gemelo?

Confiamos ciegamente en el Gemelo Digital en el núcleo (*core*) de la variedad latente entrenada; para interpolaciones locales (donde existan impactos mayores al 10 %), el modelo infiere trayectorias y voltajes muy precisos sin requerir de los prolongados 40 segundos de la simulación original. El KDE acierta efectivamente al proteger al control inverso de explorar fuera de los regímenes físicos aprendidos.

¿Dónde no confiamos?

En escenarios de extremo esparcimiento (cero transmisión prolongada por barreras muy cerradas). El modelo agrupa todos los 'impactos perdidos' en un solo sumidero latente. Por tanto, para guiar ciegamente un haz desde un inicio en que todos los iones se pierden hasta enfocarlo, el gradiente proporcionado por el Gemelo se vuelve casi nulo. Para futuras mejoras, sería conveniente añadir información del punto donde se pierden los iones en el detector para generar un espacio de fase aún más continuo. En general, el sistema demostró un control superior respaldado por fundamentos teóricos del estado del arte.